

БЛОК 1

О себе

1.1 Контекст

Я ML-инженер с продуктовым уклоном, 2 курс Центрального университета (трек «Искусственный интеллект»). Мой основной интерес — AI-продукты, где важно не только обучить модель, но и довести решение до бизнес-результата: найти пользователя, понять задачу, собрать MVP и выбрать метрику, которая отражает реальную ценность.

Сейчас веду несколько проектов с реальными клиентами: **YOS** — AI-конструктор сайтов на агентной архитектуре для МСБ-клиентов банков; **Сеченовский университет** — агент записи пациентов; **РЖД** — RAG-поддержка по базе знаний; **AR-очки для складов**. Во всех проектах занимаюсь продуктовой и ML-частями. Прошлые роли: ML-стажёр в Яндексе (RecSys), стажёр-разработчик ИИ-агентов в Сбере, бизнес-аналитик «Даркстор у дома», ML-инженер в Hired Minds (Qatar). Победитель 5+ хакатонов, в т.ч. кейс-хакатона ЦУ и Т-Банк x МГУ.

1.2 Кейс успеха — FM Logistic x «Даркстор у дома»

Кейс с чемпионата международной 3PL-компании «Логистика 2.0», апрель 2026. У FM Logistic Россия (выручка 30,1 млрд ₽ за 2024, +24,6% год к году) сильная складская база, но нет express-вертикали ≤ 60 минут. При этом доля независимых 3PL в e-com упала за 7 лет с 34% до 5,2%, а карточки с express на Ozon показывают +30% к обороту. Запускать самим долго и дорого — нужен партнёр.

Я сравнил три варианта с цифрами:

ВАРИАНТ	СТОИМОСТЬ	СРОК	ПОКРЫТИЕ	РИСК
Build (строить самим)	148 млн ₽ / 1-й год	12-18 мес	1 город	Высокий
Buy / Partner (с «Даркстор у дома»)	2,7 млн ₽ OPEX	1 квартал	88 городов	Нижe build
Do nothing	0 ₽ —	—	—	Сохраняет позиции, без роста

Что сделал лично. (1) Через личный контакт вышел на CEO «Даркстор у дома» Кирилла Чеканова и получил предварительное согласие на пилот до встречи с FM. (2) Построил финансовую модель: unit-экономика express-заказа 565 ₽, точка безубыточности — месяц 6, ROI пилота 1,4x за 8 мес. (3) Прописал KPI-гейты на 7 операционных метриках с порогами GO / PIVOT / STOP.

Результат: проект прошёл в финал конкурса FM Logistic, защита впереди. Это ещё не закрытая сделка — но это сильный продуктовый результат до стадии защиты: партнёр найден и предварительно согласен на пилот, unit-экономика собрана, KPI-гейты прописаны. Дальше — подтверждение от FM Logistic.

1.3 Кейс провала — Quest by Spiritual Data

Зима 2024–2025. На хакатоне командой из 4 человек собрали MVP сервиса для бросания курения. Чтобы не оставлять проект просто так, я вышел на американский Quest с предложением форка под смежный сценарий — отказ от зависимостей. Связался, договорился о созвоне, рассказал о нас и о идее, но получил отказ: они уже сами строили этот сценарий, просто публично не выкатили. Предложили мягкий вариант — использовать их API без форка — но это убирало главный смысл проекта (ownership и международная экспансия), мы становились внешним экспериментом на чужой платформе.

Главная ошибка: я пришёл к партнёру с готовой жёсткой формой сотрудничества (форк + ownership + международная экспансия) до того, как проверил, нужна ли им именно эта форма. Понял на самом созвоне, когда они спокойно сказали «у нас уже есть наработки». **Цена ошибки:** я не оставил себе пространства для торга — у Quest на руках был мягкий вариант (API-доступ), который мы могли бы переосмыслить и вытащить из него ценность, если бы пришли с открытой повесткой. Вместо этого я сжёг шанс на гибкий формат, потому что вся презентация была построена вокруг одной конструкции, и переключаться на ходу было поздно.

Что изменил. Перед питчем партнёру теперь делаю три проверки: (1) вакансии и публичные апдейты партнёра за 6 месяцев — если он сам строит мою вертикаль, предложение «мы сделаем за вас» обесценивается; (2) самостоятельная ценность — что у нас остаётся при отказе; (3) независимая валидация за 1–2 недели, чтобы переговорная позиция была «у нас уже есть пользователи в вашем сегменте», а не «дайте нам канал». В FM Logistic применил: первый шаг был именно самостоятельная проверка экономики, потом контакт с партнёром.

1.4 Кейс «метрика обманула» — HSTU в Яндексе

Стажировка в Яндексе, рекомендательные системы. В этот момент выходит хайповая статья от Meta — «*Actions Speak Louder than Words*» — про новую архитектуру HSTU для sequential recommendations с большими приростами офлайн-метрик на их данных. Мне ставят задачу: применить подход на нашем стеке, проверить, повторяются ли приросты на наших данных, и если да — продвигать в продакшн.

Я воспроизвёл подход, обучил модель. Офлайн-метрики (NDCG, hit rate) **выросли** — и у HSTU, и у альтернативных архитектур. Выглядело как доказанный результат. Но насторожил **слишком равномерный рост** у разных архитектур — обычно такой эффект так не работает. Стал копать и нашёл комментарий команды МТС: препроцессинг timeline вместе с positional embedding создаёт **утечку данных из будущего** — события из «будущего» попадают в контекст текущего пользователя.

Вывод. Модель не научилась лучше рекомендовать. Она научилась использовать данные, которых в продакшне у неё не будет. Офлайн-метрика оторвалась от продуктовой реальности.

БЛОК 2 Продуктовое мышление

2.1 Разбор UX/UI чата поддержки Т-Банка

Проблема 1 — слово «отмена» в чате уходит в fallback на оператора **Главный фокус**. В сценарии «Перевыпустить карту» бот предложил обновить данные в приложении. Я текстом написал «Отмена», ожидая выйти из шага или вернуться назад — система ответила «Переключаем ваш диалог на сотрудника». У бота просто нет распознавания команды «отмена / назад» внутри сценария: любой ввод вне ожидаемых слотов агент не понимает, и fallback закрывается через эскалацию.

Проблема 2 — нет явного «Назад» внутри сценария. На этапе выбора причины перевыпуска нет кнопки «Назад» или «Вернуться в меню». Если пользователь нажал не туда или передумал — единственный визуальный выход это эскалация. В одних сценариях inline-кнопки есть, в других — нет; это баг между старым и новым UX-слоями.

Проблема 3 — инструкция без deep-link в нужный экран. Бот пишет «обновите информацию о себе в приложении» с подчёркнутой ссылкой, но при тапе на неё ничего не происходит. Пользователь сам ищет раздел в приложении, ошибается, возвращается в чат — и снова попадает в тот же сценарий с теми же кнопками.

Почему «Отмена» — главный фокус. Это самый частый источник ложных эскалаций и при этом дешёвый фикс на стороне агента — добавить распознавание команды «отмена / назад / вернуться» и обработку до fallback'a. Проблема 2 решается тем же редизайном попутно. Проблема 3 (deep-link) требует интеграции с экранами приложения и более длинного цикла. «Отмена» проверяема за один спринт, эффект виден сразу.

Сколько это стоит сейчас

Часть случаев в категориях «хочет закончить диалог» (0,4%) и «зовёт оператора в середине сценария» (0,8%) — это, по моей оценке, нераспознанные команды вроде «отмена / назад». Беру консервативно ~0,6% всех чатов:

7,2 тыс. ложных эскалаций / мес	86 тыс. ложных эскалаций / год	~52 ₽ ФОТ-стоимость 1 эскалации (допущение)	~4,5 млн ₽ прямой ущерб / год
------------------------------------	-----------------------------------	---	----------------------------------

52 ₽ — допущение по ФОТ-стоимости одной эскалации (4 минуты × ~13 ₽/мин операторо-времени, индустриальный бенчмарк банковского контакт-центра). Точное число у Т-Банка может отличаться. Главное здесь не сама экономия в 4,5 млн, а то что текущие 70% переводов на оператора содержат часть случайных и UX-спровоцированных эскалаций — поэтому потенциал автоматизации занижен.

Решение и метрики

Решение в два слоя. **Слой 1 — на стороне агента:** в каждом сценарии после регистратора шага добавить распознавание команды «отмена / назад / отменить / вернуться» как возврат на предыдущий шаг сценария, а не fallback. Все агенты уже понимают команду «оператор» в тексте — нужно расширить тот же механизм на «отмена / назад» и обрабатывать его до логики выхода. То есть «Назад» и «Отмена» становятся нативным шагом сценария, без нужды в отдельных кнопках под каждым ответом бота. **Слой 2 — единственное UI-добавление:** кнопка «Отменить вызов оператора» в окне ожидания, пока не пришло первое сообщение сотрудника. У пользователя есть несколько секунд, чтобы успеть подкликнуть, если эскалация случилась по ошибке. Также нужен новый код причины `accidental_operator_call` («случайный вызов оператора»), так как это новая категория сценария.

— СЕЙЧАС

Обновите информацию о себе: сделать это можно в приложении.

Отмена

Переключаем ваш диалог на сотрудника...

→ СТАЛО

Обновите информацию о себе: [открыть в приложении](#) →

Отмена

Возвращаю на шаг «Выбрать причину». Если что-то ещё — напишите.

+ агент распознаёт «отмена», «назад», «вернуться» в тексте
 + если оператор всё-таки вызван — кнопка «Отменить вызов оператора» в окне ожидания

На какие метрики повлияет. Автоматизация растёт не за счёт удержания клиента в боте, а за счёт устранения UX-ошибок: часть переводов на оператора сейчас возникает не из-за реальной потребности в сотруднике, а из-за нераспознанных команд вроде «отмена / назад». Ожидаемый эффект: автоматизация +0,5–0,6 п.п.; CSAT сценария не должен снизиться. Дополнительно можно ввести **cancel-rate** — долю пользователей, которые успели отменить ошибочный вызов оператора до подключения сотрудника. При этом доступность оператора для реальных запросов не должна ухудшиться: если клиент явно просит человека, он должен получить оператора в разумное время.

2.2 Top of the Top — Duolingo

Что сделано хорошо. Duolingo превратил повторяемое действие в привычку через ясный прогресс и мягкое социальное давление. Самая сильная механика — **streak + лиги**. Streak создаёт личную ставку (loss aversion: чем дольше серия, тем больше терять; Streak Freeze монетизируется через подписку). Лиги добавляют социальное давление без графа друзей: ты автоматически попадаешь в группу из ~30 анонимов твоего уровня, нижние вылетают. По публичной отчётности компании DAU/MAU держится на уровне ~35% — для приложения для обучения это аномально высокий показатель.

Почему это работает. Две силы складываются мультипликативно: страх потерять стрик *на глазах у лиги* — качественно другая интенсивность, чем по отдельности. Обе механики самовоспроизводимые. Важно для PM: работает на **нулевом графе данных** — старт с первой сессии, большинству retention-механик в финтехе нужна поведенческая история.

Что улучшил бы. Та же сила превратилась в анти-паттерн: часть пользователей пишет в коммьюнити, что streak воспринимается как принуждение, а не как помощь. Я бы ввёл **soft streak** как опцию: «5 активных дней из 7 = стрик сохраняется». Гипотеза для A/B: long-term retention (12 месяцев) у когорты с soft-стриком +2–4 п.п. **Урок для финтеха.** Duolingo силён не streak'ом сам по себе, а тем, что превращает повторяемое действие в привычку через понятный прогресс и мягкое социальное давление. В банковских механиках лояльности (кэшбек-категории, статусы, миссии) ту же логику можно применять осторожно — без ощущения принуждения, чтобы пользователь воспринимал прогресс как помощь, а не как дедлайн.

БЛОК 3 План достижения 60% автоматизации

3.1 Цель и принцип плана

Бизнес-цель — увеличить автоматизацию чат-бота с 30% до 60% за 24 месяца, сохранив качество клиентского опыта. Я считаю успехом не формальное удержание клиента в боте, а реально решённое обращение: бот помог без оператора, и клиент не вернулся с той же темой в течение 7 дней.

Сейчас бот решает около 360 тыс. чатов в месяц, а на оператора уходит около 840 тыс. Чтобы выйти на 60%, нужно, чтобы бот качественно решал ещё около 360 тыс. чатов в месяц.

Иллюстрация риска через CSAT:

Сейчас: $0,30 \times 3,2 + 0,70 \times 4,1 \approx 3,83$

Если просто увеличить долю текущего бота до 60% без улучшения качества: $0,60 \times 3,2 + 0,40 \times 4,1 \approx 3,56$

Это не точный прогноз, а проверка логики: 60% автоматизации нельзя достигать через ухудшение клиентского опыта. Поэтому план строится в двух параллельных треках: расширение покрытия типовых сценариев и повышение качества решений.

Фокус плана

Дальше я смотрю на причины переводов не как на список отдельных строк, а как на портфель проблем с разной механикой решения. В фокус беру четыре типа задач.

- 1. **Где нет видимости.** 22,7% переводов не классифицированы, поэтому сначала нужно понять, что внутри этой категории.
- 2. **Где есть понятный сценарный пробел.** Если у бота нет ветки, ответа или известного намерения, это самый прямой источник роста автоматизации.
- 3. **Где бот близок к решению, но теряет качество диалога.** Это контекст, follow-up, повтор вопроса, непонятая формулировка, слоты и несколько сообщений.
- 4. **Где риск выше потенциального выигрыша.** Отключённые сегменты, особенно VIP и должники, нельзя использовать как быстрый источник роста без отдельной проверки, потому что цена ошибки там выше.

Поэтому логика плана такая: сначала убрать слепую зону и дешёвые искажения в данных, затем закрыть самые понятные сценарные пробелы, потом улучшать качество диалога и только после этого аккуратно заходить в сегменты с повышенным риском.

3.2 Как я группирую причины переводов

Чтобы не строить план по 25 разрозненным строкам, я сначала объединяю причины переводов в продукто-вые кластеры. Это показывает, где есть понятная механика решения, а где сначала нужна диагностика.

КЛАСТЕР	ИЗ ЧЕГО СКЛАДЫВАЕТСЯ	СУММА
Неклассифицированные причины	Неклассифицированные причины перевода 22,7%	22,7%
Отключённые сегменты	Бот отключён для сегмента: VIP / гость / должник 9,6%	9,6%
Пробелы сценариев / покрытия	Не хватает ветки сценария 6,7% + интент распознан, но ответа нет 3,3% + бот не знает намерения 3,1%	13,1%
Контекст и follow-up	Продолжение предыдущего диалога / контекст потерян 5,4% + клиент спрашивает в тему ответа 2,3% + клиент повторяет вопрос после ответа бота 1,4%	9,1%
Распознавание формулировок / маршрутизация	Интент есть, но не поняли формулировку 1,7% + клиент выразился слишком общо 1,0% + ошибка классификации интента 0,9% + выражает намерение в нескольких сообщениях 0,4% + несколько вопросов в одном сообщении 0,2% + другое: бот не понял 0,3%	4,5%
Парсинг ответа клиента / слоты	Бот не смог распарсить ответ клиента 1,3%	1,3%
Клиент зовёт оператора	Клиент сразу зовёт оператора 3,0% + зовёт оператора после ответа бота 1,1% + зовёт оператора в середине сценария 0,8%	4,9%
Технические ошибки и качество ответа	Техническая ошибка бота 2,6% + неперсонализированный/общий ответ 0,3% + другое: бот понял, но не решил 0,2% + бот дал неверный ответ 0,1%	3,2%
Мультимодальность	Клиент отправил только картинку/файл 0,8% + отвечает картинкой внутри сценария 0,4%	1,2%
Завершение диалога	Хочет закончить диалог 0,4%	0,4%

Итого: 70,0% переводов на оператора.

Как я перехожу от данных к плану

Логика построения roadmap такая: сначала я группирую причины переводов в кластеры, затем считаю размер каждого кластера, после этого оцениваю, какую долю кластера можно реалистично закрыть без ухудшения CSAT и роста повторных обращений. Поэтому ожидаемый вклад инициатив считается не «сверху», а по формуле:

$$\text{ожидаемый вклад} = \text{размер кластера} \times \text{реалистичная доля закрытия}$$

Дальше приоритизирую инициативы по четырём критериям: размер проблемы, понятность механики решения, риск для клиента и нагрузка на команду. Поэтому сначала идут неизвестные причины и самые понятные сценарные пробелы, а более рискованные зоны — отключённые сегменты, VIP, генеративные отве-ты и память между сессиями — не попадают в основной источник роста без отдельной проверки.

Главный вывод: самый большой блок — **22,7% неизвестных причин**. Пока он не разобран, нельзя честно сказать, какие инициативы доведут нас до 60%. Из известных кластеров самые понятные источники роста — пробелы сценариев, контекст/follow-up, распознавание формулировок и техническая стабильность.

3.3 Короткий план действий

План строю в четыре волны.

Волна 1. M1–M3 — данные, разметка и быстрые безопасные фиксы. Разбираю 22,7% неизвестных перево-дов, уточняю причины эскалаций, отдельно проверяю вызовы оператора как возможную UX-проблему из Блока 2, исправляю самые частые технические ошибки.

Волна 2. M4–M9 — доработка сценариев по самым частым пробелам. Беру ситуации, где боту не хватает ветки, ответа или понятного следующего шага. Новые ветки сначала проверяются в тестовом режиме, затем постепенно раскатываются на 10%, 25%, 50% и 100% трафика.

Волна 3. M7–M12 — контекст, follow-up и распознавание формулировок. Работаю с теми случаями, где бот не обязательно «не знает ответ», а теряет качество диалога: не понимает уточнение, повторный вопрос, несколько сообщений, общий запрос или слот. Сначала разбираю механику ошибки, затем применяю точечные решения: уточняющие вопросы, улучшение классификации интенгов, обработку нескольких сообщений, доработку парсинга слотов. ML/LLM-инструменты — только как следующий шаг, если простые методы не дают качества.

Волна 4. M13–M24 — масштабирование подтверждённых решений. Во втором году беру новые массовые причины из реклассифицированных 22,7%. Отключённые сегменты сначала разбираю на VIP / гость / должник. Guest FAQ возможен только если внутри 9,6% есть значимая доля безопасных гостевых вопросов. VIP не закладываю как источник роста до 60%.

3.4 Roadmap, вклад и обоснование

1 п.п. автоматизации = примерно **12 тыс. чатов в месяц**. Все цифры ниже — плановые допущения, а не обещание. После Q1 они пересчитываются по фактической структуре неизвестных причин.

период	инициатива	что делаю	команда	вклад	почему такой вклад
M1–M3	Реклассификация 22,7%	Разбираю неизвестные причины переводов: выборка, кластеризация, ручная проверка, новая карта причин.	1 ML, аналитик, 1 dev частично	0–1 п.п.	Сама разметка почти не автоматизирует чаты. Её задача — открыть резерв года 2; этот вклад считаю отдельно в строке новых сценариев из 22,7%.
M1–M2	UX-выход из сценария	Проверяю, какая часть «оператор в середине сценария / хочет закончить диалог» связана с «отмена / назад».	1 dev, дизайнер частично, аналитик	до +0,5–0,8 п.п.	Прямой пул: 0,8% + 0,4% = 1,2% . Не весь он UX-ошибка, поэтому беру только подтверждённую часть: 1,2% × 40–65% ≈ 0,5–0,8 п.п.
M1–M12	Техническая стабильность	Чиню техношибки, неверные и слишком общие ответы, падения сценариев.	1 dev фоном	+0,5–1,5 п.п.	Пул техношибок и плохих ответов — около 3,2% . Быстро закрыть всё нельзя: 3,2% × 15–45% ≈ 0,5–1,5 п.п. Слот-парсинг считаю отдельно.
M4–M9	Пробелы сценариев	Дорабатываю ветки по причинам: нет сценария, нет ответа, бот не знает намерение.	3–4 dev, аналитик, дизайнер частично	+5–6,5 п.п.	Размер кластера — 13,1% . Это самый прямой кластер: если закрыть 40–50% пробелов, получаем 13,1% × 40–50% ≈ 5–6,5 п.п.
M7–M12	Контекст и follow-up	Проверяю, где именно теряется контекст, и дорабатываю сценарии уточнений.	1–2 dev, ML частично	+2,7–3,6 п.п.	Размер кластера — 9,1% . Он сложнее сценарных пробелов, поэтому доля закрытия ниже: 9,1% × 30–40% ≈ 2,7–3,6 п.п.
M9–M12	Формулировки, слоты и маршрутизация	Улучшаю интенды, обработку нескольких сообщений, уточняющие вопросы и парсинг слотов.	1 ML, 1 dev	+1,5–2,3 п.п.	Пул: 4,5% формулировок/маршрутизации + 1,3% слотов = 5,8% . Кластер смешанный, поэтому закрываю не весь: 5,8% × 25–40% ≈ 1,5–2,3 п.п.
M9–M15	Клиент зовёт оператора: мягкий pre-triage	Не блокирую оператора: перед переводом предлагаю быстрый проверенный сценарий. Если клиент снова просит человека — перевожу.	1 dev, дизайнер, аналитик	+0,7–1,5 п.п.	Пул «клиент зовёт оператора» — 4,9% . Не весь пул автоматизируем: если 15–30% выберут быстрый сценарий до перевода, вклад будет 4,9% × 15–30% ≈ 0,7–1,5 п.п.
M13–M21	Новые сценарии из 22,7%	Беру подтверждённые массовые причины из реклассификации и добавляю в roadmap сценариев.	3–4 dev, аналитик, ML частично	+7–9 п.п.	Это главный резерв года 2. Если внутри 22,7% найдутся массовые безопасные coverage/context-кейсы и удастся закрыть 30–40% кластера: 22,7% × 30–40% ≈ 6,8–9,1 п.п.
M16–M24	Отключённые сегменты: безопасная часть	Сначала разбираю 9,6% на VIP / гость / должник. Автоматизирую только безопасные guest FAQ, если их доля значима.	1–2 dev, дизайнер, legal	+1–3 п.п.	В данных нет разбивки внутри 9,6%, поэтому это upside после проверки. Если значимая часть окажется гостевыми FAQ без авторизации, можно получить прирост; VIP/должников не автоматизирую агрессивно.
M22–M24	VIP opt-in пилот	Только малый пилот на проверенных сценариях. Не источник достижения 60%.	1 dev, аналитик	не закладываю	VIP — 8% базы и 35% выручки. Это аргумент осторожности, а не источник роста.

Промежуточные ориентиры: M3 — **31–32%**; M6 — **34–36%**; M9 — **37–41%**; M12 — **40–46%**; M18 — **49–55%**; M24 — **60%** в target-сценарии, если Q1 подтверждает крупную безопасную часть внутри 22,7%.

3.5 Основные гипотезы

гипотеза	почему следует из данных	как проверяю	решение
В 22,7% неизвестных причин есть автоматизируемые категории	Это самая большая категория переводов	Реклассификация выборки, ручная проверка, группировка по причинам	Делать в Q1 обязательно
Пробелы сценариев дадут основной прирост года 1	Пул 13,1% : нет ветки, нет ответа, бот не знает намерение	Беру топ-темы, делаю ветки, раскатываю постепенно	Главный фокус M4–M9
Контекст и follow-up можно частично автоматизировать	Пул 9,1% : потерян контекст, уточнения, повтор вопроса	Сначала выясняю механику: потеря контекста, неполный ответ или плохой переход	Запускать после первых сценарных доработок
Проблемы формулировок и слотов можно снизить улучшением маршрутизации	Пул около 5,8% : формулировки, общий запрос, ошибка интенга, несколько сообщений, слоты	Сначала правила, интенг-классификация, уточнения, слоты; ML/LLM — второй шаг	Запускать после того, как есть рабочие сценарии
Технические ошибки нужно чинить фоном	Около 3,2% чатов связаны с техношибками и плохими ответами	Еженедельный разбор топовых падений и неверных ответов	Не главный рост, но защита CSAT

ГИПОТЕЗА	ПОЧЕМУ СЛЕДУЕТ ИЗ ДАННЫХ	КАК ПРОВЕРЯЮ	РЕШЕНИЕ
UX-спровоцированные вызовы оператора возможны, но требуют проверки	В Блоке 2 найден кейс «отмена → оператор»; в данных есть «зовёт оператора в середине» и «хочет закончить диалог»	Смотрю логи перед вызовом оператора: текст, шаг сценария, команды «назад / отмена»	Быстрый тест в Q1; вклад не считаю гарантированным
Отключённые сегменты нельзя автоматизировать одной логикой	В данных 9,6% , но без разбивки на VIP / гость / должник	Сначала разбиваю сегмент и считаю безопасную долю	Guest FAQ — только после подтверждения; VIP не в основной вклад

3.6 Backlog-гипотезы — что сознательно не входит в основной план

Эти гипотезы не входят в базовый путь к 60%, потому что основной план даёт более предсказуемый вклад при меньшем риске и меньшей нагрузке на команду. Но я не выбрасываю их: это backlog для discovery-задач. Если основные волны недодают вклад или появляется свободная capacity, возвращаюсь к ним и проверяю по тем же критериям: размер проблемы, риск, стоимость и ожидаемый эффект.

ГИПОТЕЗА	ПОЧЕМУ ИНТЕРЕСНА	ЭФФЕКТ	ПОЧЕМУ НЕ СЕЙЧАС	КОМУ ОТДАТЬ
Мультимодальные обращения	В данных есть 1,2% : картинка/файл 0,8% + картинка внутри сценария 0,4%.	до +0,3–0,6 п.п.	Маленький пул, высокая сложность OCR/vision, риск ошибок на документах и скриншотах.	ML-интерн + аналитик: разметка 300–500 кейсов.
Память между сессиями	Может быть частью 5,4% «продолжение предыдущего диалога / контекст потерян».	до +1–2 п.п. после проверки	Не ясно, это потеря внутри сессии или между сессиями. Есть риск хранения данных и неверной персонализации.	Аналитик / junior PM: когортный анализ повторных обращений.
Полноценный генеративный бот	Может помочь с нестандартными вопросами, которые не закрываются сценариями.	не закладываю	В банковском контексте высокий риск уверенных неверных ответов. Сначала сценарии, маршрутизация и guardrails.	ML-интерн: анализ guardrails и ошибок на исторических кейсах.
Автоматизация должников	Должники входят в общий кластер 9,6% отключённых сегментов.	не закладываю	Нет разбивки внутри 9,6%. Высокий юридический и репутационный риск.	Аналитик + legal: сегментация 9,6% и карта допустимых тем.
Распознавание фрустрации клиента	Косвенно может проявляться перед эскалациями: «зовёт после ответа» 1,1% и «зовёт в середине сценария» 0,8%.	не прямой рост automation	В данных нет отдельной категории фрустрации. Это скорее защита CSAT, а не путь к 60%.	ML-интерн + аналитик: словарь маркеров и ручная проверка выборки.
Автоматическое резюме для оператора	Может снизить повторное объяснение проблемы при эскалации и улучшить опыт клиента.	не влияет напрямую	Это задача эффективности операторов, а не роста доли автоматизированных чатов. В кейсе есть время ответа, но не АНТ.	Junior PM / аналитик: пилот на 1–2 сценариях эскалации.
Проактивная поддержка	Может заранее снижать часть обращений: статусы переводов, лимиты, комиссии, ошибки операций.	не считаю в 60%	Это снижение входящего потока, а не автоматизация текущих чатов. Отдельная продуктовая стратегия.	Product intern: discovery по топ-темам и proactive-сигналам.
Голосовой ввод с суммаризацией	Может помочь, если клиент не может коротко описать проблему текстом: общий запрос 1,0%, несколько сообщений 0,4%, несколько вопросов 0,2%.	не закладываю	Голос в данных не указан. Новая модальность, speech-to-text, риск ошибок суммаризации и чувствительных данных. Сначала — структурированный ввод и уточняющие вопросы.	ML-интерн + дизайнер: прототип и анализ длинных неструктурированных сообщений.

Вывод. Эти гипотезы не плохие — они просто проигрывают основному плану по соотношению вклад / риск / нагрузка. В первые 12 месяцев команда фокусируется на том, что прямо следует из данных: реклассификация 22,7%, пробелы сценариев, контекст/follow-up, формулировки/слоты и техническая стабильность. Backlog использую как резерв задач для стажёров, аналитиков и junior PM, чтобы они готовили доказательную базу, не отвлекая основную команду от roadmap.

3.7 Почему такие приоритеты

Приоритет считаю так:

размер проблемы × ожидаемый вклад × уверенность / сложность и риск

Поэтому сначала иду в **22,7% неизвестных причин**: без этого год 2 будет строиться вслепую. Затем — **пробелы сценариев**, потому что это самый понятный атакуемый кластер: **13,1% всех чатов**. После этого — **контекст и формулировки**, потому что они работают лучше, когда уже есть сценарии, куда можно направить клиента.

Технические ошибки идут фоном: они не дают главный прирост, но защищают доверие к боту. **UX-выход** проверяю быстро, потому что в Блоке 2 уже найден конкретный пример, но не закладываю большой эффект без логов. **Отключённые сегменты** не использую как быстрый источник роста, потому что в одной строке смешаны VIP, гости и должники. Без разбивки это слишком рискованно.

Из-за ограниченной команды ML-задачи не запускаются одновременно: сначала реклассификация неизвестных причин, затем улучшение маршрутизации и только после этого более сложные ML/LLM-инструменты, если они действительно нужны.

3.8 Метрики и ограничения релиза

МЕТРИКА	ЗАЧЕМ НУЖНА
CSAT бота	Проверяет, не покупаем ли автоматизацию ухудшением опыта
CSAT по сценарию	Ловит плохие сценарии, которые скрываются в среднем
Repeat-contact-7d	Главный детектор формальной автоматизации
Repeat-contact-24h	Быстрый сигнал, что бот не решил вопрос
Эскалация после ответа бота	Показывает ответы, которые не помогают
Ошибочная маршрутизация	Критично для интенгов и возможной ML/LLM-прослойки
Время ожидания оператора	В кейсе дано 4 минуты как время ответа оператора, не АНТ
Cost per automated chat	Нужно для инициатив с ML / LLM

Правило релиза: новый сценарий раскатывается постепенно. Если растут повторные обращения, падает CSAT или увеличивается ошибочная маршрутизация — откат и разбор причины.

3.9 Риски

РИСК	КАК ЗАМЕЧАЮ	ЧТО ДЕЛАЮ
Формальная автоматизация	Автоматизация растёт, но repeat-contact-7d тоже растёт	Не засчитываю такой рост, откатываю сценарий
22,7% окажутся неавтоматизируемыми	После реклассификации мало массовых безопасных тем	Пересобираю год 2, усиливаю сценарии, контекст и безопасные сегменты
Падение CSAT	CSAT бота или сценария падает на rollout	Откат до прошлой ступени
Перегруз ML-инженера	ML-задачи блокируют roadmap	Не запускаю одновременно реклассификацию, маршрутизацию и сложную память
Дорогой ML/LLM без эффекта	Стоимость обработки растёт, а вклад малый	Начинаю с правил, выборок и кластеров; ML/LLM только после проверки
VIP-инцидент	Ошибка или жалоба в дорогом сегменте	VIP по умолчанию остаётся у оператора
Compliance по памяти	Нужно хранить данные между сессиями	В основной план беру только контекст текущего диалога

3.10 Целевое состояние через 24 месяца

Через 24 месяца целевое состояние — **60% качественной автоматизации**. Бот закрывает массовые, повторяемые и безопасные сценарии: карты, переводы, лимиты, подписки, навигация, типовые FAQ и новые сценарии из реклассифицированных причин.

Оператор остаётся для сложных, эмоциональных, юридически чувствительных сценариев, включая спорные и финансово рискованные обращения должников, а также для VIP по умолчанию.

Финальный месседж. Рост автоматизации достигается не через удержание клиента в боте любой ценой, а через понятные сценарии, контроль повторных обращений, постепенную раскатку и ограничения по качеству.